

An Overview of the Convergence of Muon

目录

1	所有 Muon 收敛证明共同依赖的矩阵几何	4
2	一个统一的 Muon proof skeleton	5
3	Li-Hong: 第一代 normalized-momentum 分析	7
3.1	Assumptions	7
3.2	论文声称的关键 descent inequality	7
3.3	Momentum error recursion	7
3.4	需要注意的 proof gap	8
4	Shen et al.: 把 Muon 放回正确的 spectral/nuclear geometry	9
4.1	Spectral smoothness	9
4.2	Theorem 4.7 的显式上界	10
4.3	Deterministic case	11
4.4	Λ -smoothness 与 Hessian 结构	11
4.5	不假设统一 smoothness: 平均 Hessian curvature	11
5	Sato-Naganuma-Iiduka: Nesterov、weight decay 与 practical configurations	13
5.1	四种算法配置	13
5.2	Weight decay 为什么能证明 iterates bounded	13
5.3	One-step inequality	14
5.4	最终 rate	14

目录	2
6 Kovalev: Muon 是 spectral-norm trust-region step	15
6.1 Star-convex + weight decay	15
7 Chen–Li–Liu: Muon 隐式优化 spectral-norm constrained problem	17
7.1 按论文符号写出的更新	17
7.2 Fenchel conjugate 给出 spectral constraint	17
7.3 Constraint violation Lyapunov function	18
7.4 KKT stationarity score	18
8 Sfyraiki–Wang: Muon with weight decay 等价于 stochastic Frank–Wolfe	19
8.1 Frank–Wolfe gap	19
8.2 Theorem 3 的 rate	20
9 Kim–Oh: finite-step Newton–Schulz 如何进入主定理	21
9.1 Proof 中最关键的拆分	21
9.2 Theorem 1	22
9.3 Theorem 2: double-exponential approximation	22
10 Chang–Liu–Yuan: MVR2 如何把 $T^{-1/4}$ 提升到 $T^{-1/3}$	23
10.1 MVR1	23
10.2 MVR2: same-sample gradient difference	23
10.3 MVR2 tracking recursion	23
10.4 与 descent inequality 的耦合	24
10.5 PL condition	25
11 NAMO / NAMO-D: 怎样把 Adam-style adaptation 接到 Muon 上	26
11.1 Assumptions	26
11.2 NAMO update	26
11.3 Bias correction 写成 convex combination	26
11.4 Surrogate function	27
11.5 Deterministic rate	27

目录	3
11.6 Stochastic rate	28
11.7 NAMO-D	28
12 Nagashima–Iiduka: 统一 learning-rate / batch schedule 上界	30
12.1 Algorithm	30
12.2 Theorem 3.1 的 master bound	30
12.3 Constant schedule	31
12.4 Diminishing schedule	32
13 把这些证明放在同一张逻辑图中	33
13.1 第一类: ordinary momentum tracking	33
13.2 第二类: variance-reduced momentum	33
13.3 第三类: approximate orthogonalization	34
13.4 第四类: constraint / Frank–Wolfe geometry	34

1 所有 Muon 收敛证明共同依赖的矩阵几何

设矩阵 $M \in \mathbb{R}^{m \times n}$ 的 compact SVD 为

$$M = U\Sigma V^\top,$$

定义它的 polar factor 或 matrix sign 为

$$\text{msign}(M) = UV^\top = M(M^\top M)^{\dagger/2}.$$

记

$$O = \text{msign}(M).$$

它满足三个关键恒等式：

$$\langle M, O \rangle_F = \|M\|_*$$

$$\|O\|_{\text{op}} \leq 1$$

以及

$$\|O\|_F^2 = \text{rank}(M) \leq r, \quad r := \min\{m, n\}.$$

第一条尤其重要，因为 nuclear norm 与 spectral norm 互为 dual norms：

$$\|M\|_* = \max_{\|O\|_{\text{op}} \leq 1} \langle M, O \rangle_F.$$

因此

$$-\text{msign}(M) \in \arg \min_{\|D\|_{\text{op}} \leq 1} \langle M, D \rangle_F.$$

所以 exact-polar Muon 并不只是“把矩阵正交化”，而是在 spectral-norm unit ball 中求解一个 steepest-descent linear subproblem。[Shen et al., 2025]

还要注意三种梯度指标的关系：

$$\|\nabla f(X)\|_F \leq \|\nabla f(X)\|_* \leq \sqrt{r} \|\nabla f(X)\|_F.$$

因此：

- 控制 nuclear norm stationarity 通常比控制 Frobenius norm stationarity 更强；
- 把 Frobenius 结果转换成 nuclear 结果，往往要付出 $\sqrt{r}$ ；
- 不同论文报告的 convergence rate，不能只看 T 的指数，还要看它控制的 norm。

2 一个统一的 Muon proof skeleton

考虑 idealized Muon:

$$\begin{aligned} G_t &= \frac{1}{B} \sum_{i=1}^B \nabla F(X_t; \xi_{t,i}), \\ M_t &= \beta_t M_{t-1} + (1 - \beta_t) G_t, \\ O_t &= \text{msign}(M_t), \quad X_{t+1} = X_t - \eta_t O_t. \end{aligned}$$

假设目标函数满足与 Muon 几何匹配的 spectral smoothness:

$$f(Y) \leq f(X) + \langle \nabla f(X), Y - X \rangle_F + \frac{L_*}{2} \|Y - X\|_{\text{op}}^2.$$

因为 $\|O_t\|_{\text{op}} \leq 1$, 所以

$$f(X_{t+1}) \leq f(X_t) - \eta_t \langle \nabla f(X_t), O_t \rangle_F + \frac{L_* \eta_t^2}{2}.$$

现在把真实梯度拆成 momentum estimator 加误差:

$$\nabla f(X_t) = M_t + (\nabla f(X_t) - M_t).$$

于是

$$\begin{aligned} \langle \nabla f(X_t), O_t \rangle_F &= \langle M_t, O_t \rangle_F + \langle \nabla f(X_t) - M_t, O_t \rangle_F \\ &\geq \|M_t\|_* - \|\nabla f(X_t) - M_t\|_*. \end{aligned}$$

又由 triangle inequality,

$$\|M_t\|_* \geq \|\nabla f(X_t)\|_* - \|\nabla f(X_t) - M_t\|_*.$$

所以得到 Muon 分析里最核心的不等式:

$$\boxed{\langle \nabla f(X_t), O_t \rangle_F \geq \|\nabla f(X_t)\|_* - 2\|\nabla f(X_t) - M_t\|_*}.$$

代回 descent lemma:

$$\boxed{\begin{aligned} \eta_t \|\nabla f(X_t)\|_* &\leq f(X_t) - f(X_{t+1}) \\ &\quad + 2\eta_t \|\nabla f(X_t) - M_t\|_* \\ &\quad + \frac{L_* \eta_t^2}{2}. \end{aligned}} \quad (\text{Master descent})$$

对 t 求和后, function-value 部分 telescopes:

$$\sum_{t=0}^{T-1} (f(X_t) - f(X_{t+1})) = f(X_0) - f(X_T) \leq \Delta,$$

其中

$$\Delta = f(X_0) - f^*.$$

因此所有问题都转化成控制

$$\mathbb{E}\|\nabla f(X_t) - M_t\|$$

这个 momentum tracking error。

这就是为什么 Muon 论文看起来变化很多，实际上大部分证明的差别只在于：

1. 用什么 norm 写 descent;
2. 怎样控制 $M_t - \nabla f(X_t)$;
3. orthogonalization 是 exact polar 还是 approximate Newton-Schulz;
4. 是否加入 variance reduction、weight decay 或 adaptive denominator。

3 Li-Hong: 第一代 normalized-momentum 分析

3.1 Assumptions

Li 与 Hong 采用普通 Frobenius L -smoothness:

$$\|\nabla f(X) - \nabla f(Y)\|_F \leq L\|X - Y\|_F,$$

以及 unbiased bounded-variance oracle:

$$\mathbb{E}[G_t | X_t] = \nabla f(X_t),$$

$$\mathbb{E}\|G_t - \nabla f(X_t)\|_F^2 \leq \frac{\sigma^2}{B}.$$

算法为

$$B_t = \beta B_{t-1} + (1 - \beta)G_t,$$

$$O_t = \text{msign}(B_t), \quad X_{t+1} = X_t - \eta O_t.$$

3.2 论文声称的关键 descent inequality

他们的 Lemma 2.1 给出类似

$$-\langle \nabla f(X_t), O_t \rangle_F \leq -\frac{1}{4}\|\nabla f(X_t)\|_F + \frac{5}{2}\|\nabla f(X_t) - B_t\|_F.$$

结合 Frobenius smoothness 以及

$$\|O_t\|_F^2 \leq n,$$

得到

$$\boxed{\begin{aligned} f(X_{t+1}) &\leq f(X_t) - \frac{\eta}{4}\|\nabla f(X_t)\|_F \\ &\quad + \frac{5}{2}\eta\|\nabla f(X_t) - B_t\|_F + \frac{nL\eta^2}{2}. \end{aligned}}$$

注意这里最后出现的是 $nL\eta^2$, 而 spectral-smooth analysis 中对应项只是 $L_*\eta^2$ 。这正是 norm geometry 选择带来的 dimension factor。

3.3 Momentum error recursion

定义

$$\hat{\delta}_t = B_t - \nabla f(X_t),$$

$$\delta_t = G_t - \nabla f(X_t).$$

由 momentum recursion,

$$\begin{aligned}\widehat{\delta}_{t+1} &= \beta B_t + (1 - \beta)G_{t+1} - \nabla f(X_{t+1}) \\ &= \beta \widehat{\delta}_t + (1 - \beta)\delta_{t+1} \\ &\quad + \beta(\nabla f(X_t) - \nabla f(X_{t+1})).\end{aligned}$$

最后一项是 **drift error**, 因为 momentum 中混入的是旧位置的梯度。利用 smoothness,

$$\|\nabla f(X_t) - \nabla f(X_{t+1})\|_F \leq L\eta\|O_t\|_F \leq L\eta\sqrt{n}.$$

递推展开以后得到典型结构

$$\mathbb{E}\|\widehat{\delta}_t\|_F \lesssim \underbrace{\beta^t \mathbb{E}\|\widehat{\delta}_0\|_F}_{\text{initialization}} + \underbrace{\sigma \sqrt{\frac{1-\beta}{B}}}_{\text{stochastic noise}} + \underbrace{\frac{L\eta\sqrt{n}}{1-\beta}}_{\text{gradient drift}}.$$

于是总上界大致变成

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}\|\nabla f(X_t)\|_F \lesssim \frac{\Delta}{\eta T} + nL\eta + \sigma\sqrt{1-\beta} + \frac{L\eta\sqrt{n}}{1-\beta}.$$

平衡后产生 stochastic $T^{-1/4}$ 项。例如 Theorem 2.1 的主要形式为

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}\|\nabla f(X_t)\|_F \leq O\left(\frac{\sqrt{nL\Delta}}{\sqrt{T}} + \frac{\sqrt{\sigma}(L\Delta)^{1/4}}{T^{1/4}} + \frac{\sigma^2}{\sqrt{L\Delta T}}\right).$$

3.4 需要注意的 proof gap

后来的 Chang-Liu-Yuan 指出该早期证明使用了不正确的矩阵不等式。对正定对角矩阵 S , 正确关系是

$$\|S^{-1}\|_2 = \frac{1}{\sigma_{\min}(S)},$$

而不是

$$\|S^{-1}\|_2 \leq \frac{1}{\|S\|_2} = \frac{1}{\sigma_{\max}(S)}.$$

事实上方向一般相反:

$$\|S^{-1}\|_2 \geq \frac{1}{\|S\|_2}.$$

所以 Li-Hong 的公式非常适合用来理解**第一代 proof template**, 但其原始 theorem 不能不加保留地当成最终严格结论。[Li and Hong, 2025]

4 Shen et al.: 把 Muon 放回正确的 spectral/nuclear geometry

这篇最值得仔细读，因为它明确区分了：

- Frobenius smoothness;
- spectral smoothness;
- Λ -smoothness;
- Hessian-average analysis。

4.1 Spectral smoothness

他们使用的核心条件是

$$\|\nabla f(W) - \nabla f(W')\|_* \leq L_* \|W - W'\|_{\text{op}}.$$

对应 descent inequality:

$$f(W') \leq f(W) + \langle \nabla f(W), W' - W \rangle_F + \frac{L_*}{2} \|W' - W\|_{\text{op}}^2.$$

对 Muon 更新

$$W_{t+1} = W_t - \eta O_t$$

而言，因为 $\|O_t\|_{\text{op}} = 1$ ，smoothness penalty 是

$$\frac{L_* \eta^2}{2},$$

而不是 Frobenius 分析中的

$$\frac{r L \eta^2}{2}.$$

4.2 Theorem 4.7 的显式上界

论文得到

$$\begin{aligned}
 \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E} \|\nabla f(W_t)\|_* &\leq \frac{\mathbb{E}[f(W_0) - f(W_T)]}{T\eta} + \frac{L_*\eta}{2} \\
 &\quad + \frac{2\sigma\sqrt{r(1-\beta)}}{\sqrt{(1+\beta)B}} \\
 &\quad + \frac{2\beta\sigma\sqrt{r}}{(1-\beta)T\sqrt{B}} \\
 &\quad + \frac{2\eta\beta L_*}{1-\beta}.
 \end{aligned}
 \tag{Shen Thm. 4.7}$$

这里五项分别是：

$$\begin{aligned}
 \frac{\Delta}{T\eta} &\quad \text{optimization term,} \\
 L_*\eta &\quad \text{smoothness term,} \\
 \sigma\sqrt{\frac{r(1-\beta)}{B}} &\quad \text{stationary momentum variance,} \\
 \frac{\sigma\sqrt{r}}{(1-\beta)T\sqrt{B}} &\quad \text{initial transient,} \\
 \frac{\eta L_*}{1-\beta} &\quad \text{momentum drift.}
 \end{aligned}$$

取 $B = 1$ ，并选择

$$\begin{aligned}
 \eta &= \sqrt{\frac{(1-\beta)\Delta}{TL_*}}, \\
 1-\beta &= \min \left\{ \frac{\sqrt{L_*\Delta}}{\sigma\sqrt{rT}}, 1 \right\},
 \end{aligned}$$

得到

$$\frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E} \|\nabla f(W_t)\|_* \leq O \left[\left(\frac{rL_*\Delta\sigma^2}{T} \right)^{1/4} + \sqrt{\frac{L_*\Delta}{T}} + \frac{r\sigma^2}{\sqrt{L_*\Delta T}} \right].$$

最慢的主项仍然是

$$T^{-1/4}.$$

但这里结论是 nuclear-norm stationarity，并且 smoothness constant 是与 Muon geometry 对齐的 L_* 。

4.3 Deterministic case

当 $\sigma = 0$ 时, momentum variance 消失, 取

$$\eta \asymp \sqrt{\frac{\Delta}{L_* T}},$$

得到

$$\boxed{\frac{1}{T} \sum_{t=0}^{T-1} \|\nabla f(W_t)\|_* \leq O\left(\sqrt{\frac{L_* \Delta}{T}}\right).}$$

也就是平均 gradient norm 的最优 deterministic nonconvex 一阶阶数 $T^{-1/2}$ 。

4.4 Λ -smoothness 与 Hessian 结构

他们还定义

$$\|\nabla f(W) - \nabla f(W')\|_{\Lambda^{-1}} \leq \|W - W'\|_{\Lambda}.$$

在二阶可微情况下, 可写成 Hessian sandwich:

$$\boxed{-I_m \otimes \Lambda \preceq \nabla^2 f_v(w) \preceq I_m \otimes \Lambda.}$$

如果 Λ 的 effective rank 很低, 则

$$\|\Lambda\|_* \ll r \|\Lambda\|_{\text{op}}.$$

于是 Muon 对应的常数规模可能是

$$\|\Lambda\|_* D_{\text{op}}^2,$$

而 vectorized GD 的规模近似是

$$r \|\Lambda\|_{\text{op}} D_{\text{op}}^2.$$

这比“Muon 的 T -指数比 GD 更快”更准确: 它的理论优势主要体现在**结构常数更小**。

4.5 不假设统一 smoothness: 平均 Hessian curvature

他们还考虑沿轨迹的 Hessian curvature:

$$J_t = \text{vec}(O_t)^\top H_t \text{vec}(O_t),$$

$$J = \frac{1}{T} \sum_{t=0}^{T-1} J_t.$$

Theorem 4.14 给出

$$\frac{1}{T} \sum_{t=0}^{T-1} \|\nabla f(W_t)\|_* \leq \frac{f(W_0) - f(W_T)}{T\eta} + \frac{\eta J}{2} + \frac{s\eta^2 r^{3/2}}{6}.$$

这说明证明实际上只需要控制 **Muon** 真正走过的方向上的平均 curvature，未必需要一个很大的 global Lipschitz constant。[Shen et al., 2025]

5 Sato–Naganuma–Iiduka: Nesterov、weight decay 与 practical configurations

5.1 四种算法配置

基础 momentum:

$$M_t = \beta M_{t-1} + (1 - \beta) \nabla f_{S_t}(W_t).$$

普通 Muon 取

$$C_t = M_t.$$

Nesterov Muon 取

$$C_t = \beta M_t + (1 - \beta) \nabla f_{S_t}(W_t).$$

随后

$$O_t = \text{NewtonSchulz}_k(C_t).$$

带 decoupled weight decay 时,

$$\boxed{W_{t+1} = (1 - \eta\lambda)W_t - \eta O_t.}$$

5.2 Weight decay 为什么能证明 iterates bounded

假设

$$\eta \leq \frac{1}{\lambda}.$$

因为 $\|O_t\|_F \leq \sqrt{r_2}$, 递推得

$$\|W_{t+1}\|_F \leq (1 - \eta\lambda)\|W_t\|_F + \eta\sqrt{r_2}.$$

展开:

$$\boxed{\|W_t\|_F \leq (1 - \eta\lambda)^t \|W_0\|_F + \frac{\sqrt{r_2}}{\lambda}.$$

从而在 L -smoothness 下,

$$\begin{aligned} \|\nabla f(W_t)\|_F &\leq L\|W_t - W^*\|_F \\ &\leq L(1 - \eta\lambda)^t \|W_0\|_F + \frac{L\sqrt{r_2}}{\lambda} + L\|W^*\|_F. \end{aligned}$$

因此 weight decay 的主要理论功能不是提高 T 的指数, 而是从算法本身推出

$$\sup_t \|W_t\|_F < \infty, \quad \sup_t \|\nabla f(W_t)\|_F < \infty.$$

5.3 One-step inequality

论文的 descent 结构可以概括成

$$\begin{aligned} f(W_{t+1}) \leq & f(W_t) - (1 - \lambda)\eta \|\nabla f(W_t)\|_* \\ & + 2\sqrt{r_1}\eta \|\nabla f(W_t) - C_t\|_F \\ & + (r_2 + \lambda^2 r_3)L\eta^2. \end{aligned}$$

这里：

- r_1 来自把 nuclear/operator pairing 转成 Frobenius error;
- r_2 控制 orthogonalized update;
- r_3 控制 weight decay 中的 iterate norm。

5.4 最终 rate

Theorem 3.2 的主结构是

$$\frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E} \|\nabla f(W_t)\|_* = O\left(\frac{1}{\eta T} + \sqrt{\frac{(1-\beta)r_1}{b}} + \hat{r}\eta\right),$$

其中

$$\hat{r} = \max\{r_1, r_2, r_3\}.$$

选择

$$\eta = T^{-3/4}, \quad 1 - \beta = T^{-1/2},$$

则

$$\begin{aligned} \frac{1}{\eta T} &= T^{-1/4}, \\ \sqrt{1 - \beta} &= T^{-1/4}, \end{aligned}$$

而

$$\eta = T^{-3/4}$$

更小，所以总体为

$$O(T^{-1/4}).$$

这篇论文的价值主要在于：同一个 proof template 能覆盖 Nesterov、weight decay、finite Newton–Schulz error 和 critical batch size，而不是提高基础 rate。[Sato et al., 2025]

6 Kovalev: Muon 是 spectral-norm trust-region step

Kovalev 的构造不是从“正交化”出发，而是从一个 non-Euclidean trust-region sub-problem 出发：

$$x_{k+1} \in \arg \min_x \mathcal{A}(x; x_k) \quad \text{s.t.} \quad \|x - x_k\| \leq \eta.$$

若模型只是线性化

$$\mathcal{A}(X; X_k) = f(X_k) + \langle G_k, X - X_k \rangle_F,$$

并选择 spectral trust region：

$$\|X - X_k\|_{\text{op}} \leq \eta,$$

则令 $\Delta = X - X_k$ ，子问题为

$$\min_{\|\Delta\|_{\text{op}} \leq \eta} \langle G_k, \Delta \rangle_F.$$

由 duality,

$$\boxed{\Delta_k = -\eta \text{msign}(G_k).}$$

这直接导出 Muon step：

$$X_{k+1} = X_k - \eta \text{msign}(G_k).$$

所以 Muon 是：

$$\boxed{\text{spectral-norm trust-region steepest descent.}}$$

6.1 Star-convex + weight decay

他们采用的 star-convex 条件形如

$$f(\beta x^* + (1 - \beta)x) \leq \beta f(x^*) + (1 - \beta)f(x).$$

带 shrinkage 的 trust region 可以写成

$$x_{k+1} = \arg \min_x \mathcal{A}(x; x_k)$$

subject to

$$\boxed{\|x - (1 - \beta)x_k\| \leq \eta.}$$

也就是 trust region 的中心不是 x_k ，而是 weight-decayed point $(1 - \beta)x_k$ 。

Theorem 3 给出类似

$$F(x_K) - F(x^*) \leq (1 - \beta)^K (F(x_0) - F(x^*)) + \frac{4L\eta^2}{\beta}.$$

第一项是 geometric contraction, 第二项是 trust-region approximation floor。

取

$$\eta = \beta D,$$

并令

$$\beta \asymp \min \left\{ 1, \frac{\varepsilon}{LD^2} \right\},$$

可得到

$$K = \tilde{O} \left(\max \left\{ 1, \frac{LD^2}{\varepsilon} \right\} \right).$$

这条 proof line 的主要意义是解释 Muon 的几何来源, 而不是只给出一个 normalized-gradient error bound。[Kovalev, 2025]

7 Chen-Li-Liu: Muon 隐式优化 spectral-norm constrained problem

这篇把 Muon 放进 Lion- $\mathcal{K}$ 框架。

7.1 按论文符号写出的更新

$$\begin{aligned} M_{t+1} &= \beta_2 M_t - (1 - \beta_2) G_t, \\ \widetilde{M}_{t+1} &= \beta_1 M_t - (1 - \beta_1) G_t, \\ X_{t+1} &= X_t + \eta_t \left(\text{msign}(\widetilde{M}_{t+1}) - \lambda X_{t+1} \right). \end{aligned}$$

关键观察是选择

$$\mathcal{K}(M) = \|M\|_*.$$

因为 nuclear norm 的 generalized gradient 与 matrix sign 对应：

$$\nabla \mathcal{K}(M) \sim \text{msign}(M).$$

7.2 Fenchel conjugate 给出 spectral constraint

对

$$\mathcal{K}(M) = \|M\|_*,$$

其 convex conjugate 为

$$\boxed{\mathcal{K}^*(Y) = \iota_{\{\|Y\|_{\text{op}} \leq 1\}}(Y),}$$

其中 indicator function 定义为

$$\iota_{\mathcal{C}}(Y) = \begin{cases} 0, & Y \in \mathcal{C}, \\ +\infty, & Y \notin \mathcal{C}. \end{cases}$$

因此对应 regularized objective

$$\widehat{F}(X) = F(X) + \frac{1}{\lambda} \mathcal{K}^*(\lambda X)$$

实际上等价于

$$\boxed{\min_X F(X) \quad \text{s.t.} \quad \|X\|_{\text{op}} \leq \frac{1}{\lambda}.}$$

也就是说, decoupled weight decay 并不只是普通的 Euclidean L^2 regularization; 在这一动力系统解释下, 它与 spectral-norm constraint 联系起来。

7.3 Constraint violation Lyapunov function

定义

$$\mathcal{V}_{\mathbb{B}}(X) = \max \left\{ \|X\|_{\text{op}} - \frac{1}{\lambda}, 0 \right\}.$$

论文证明

$$\mathcal{V}_{\mathbb{B}}(X_t) \leq \left[\prod_{s=0}^{t-1} (1 - \eta_s \lambda) \right] \mathcal{V}_{\mathbb{B}}(X_0).$$

因此只要

$$\sum_s \eta_s = \infty,$$

constraint violation 就趋向于零。

7.4 KKT stationarity score

他们定义的 KKT-type score 可以写为

$$S(X) = \|\nabla F(X)\|_* + \langle \lambda X, \nabla F(X) \rangle_F.$$

第一项来自 spectral ball 上 linear minimization oracle, 第二项来自当前位置 X 。

相应 Lyapunov function 为

$$\mathcal{V}_{\mathcal{K}}(X, M) = F(X) - F^* + \frac{c}{\lambda} (\|M\|_* - \langle \lambda X, M \rangle_F).$$

第二部分本质上是一个 Fenchel gap。

论文的 finite-time 结果具有形式

$$\min_{1 \leq t \leq T} \mathbb{E} S(X_t) = O \left(T^{-1/2} + \sqrt{\frac{\sigma}{n_{\text{batch}}}} \right),$$

而在 Robbins–Monro 条件

$$\sum_t \eta_t = \infty, \quad \sum_t \eta_t^2 < \infty, \quad \eta_t \leq \frac{1}{\lambda}$$

下, 可以得到向 constrained problem 的 KKT set 收敛的结论。[Chen et al., 2025]

8 SfyraKI–Wang: Muon with weight decay 等价于 stochastic Frank–Wolfe

这篇与上一节的 constrained interpretation 高度相关，但它直接采用 Frank–Wolfe language。

设 constraint set 为 spectral ball:

$$\mathcal{C} = \left\{ A : \|A\|_{\text{op}} \leq \frac{1}{\lambda} \right\}.$$

Frank–Wolfe linear minimization oracle 为

$$s_t \in \arg \min_{A \in \mathcal{C}} \langle A, G_t \rangle_F.$$

利用 nuclear/spectral duality,

$$s_t = -\frac{1}{\lambda} \text{msign}(G_t).$$

标准 FW 更新

$$X_{t+1} = (1 - \gamma_t)X_t + \gamma_t s_t$$

因此变成

$$X_{t+1} = (1 - \gamma_t)X_t - \frac{\gamma_t}{\lambda} \text{msign}(G_t),$$

这与带 weight decay 的 Muon 更新同构。

8.1 Frank–Wolfe gap

定义

$$\mathcal{G}(X) = \max_{V \in \mathcal{C}} \langle V - X, -\nabla F(X) \rangle_F.$$

代入 spectral ball:

$$\begin{aligned} \mathcal{G}(X) &= \max_{\|V\|_{\text{op}} \leq 1/\lambda} [-\langle V, \nabla F(X) \rangle_F + \langle X, \nabla F(X) \rangle_F] \\ &= \boxed{\frac{1}{\lambda} \|\nabla F(X)\|_* + \langle X, \nabla F(X) \rangle_F}. \end{aligned}$$

这与 Chen–Li–Liu 的 KKT score 是同一个几何量的不同 normalization。

8.2 Theorem 3 的 rate

在相应 smoothness、bounded variance 和 momentum assumptions 下，随机选取输出迭代 X_a ，他们得到

$$\mathbb{E}\mathcal{G}(X_a) = O\left(\frac{D\left(F(X_1) - F(X^*) + L\left(\frac{1}{2} + \frac{\beta}{\gamma}\right)\right)}{\sqrt{T}} + \frac{D\sigma}{\sqrt{m}}\left(\frac{\beta}{\gamma(1-\gamma)} + 1\right)\right).$$

这里 m 是 batch size。若取

$$m = T,$$

则 gradient-noise term 也成为 $O(T^{-1/2})$ ，因此

$$\mathbb{E}\mathcal{G}(X_a) = O(T^{-1/2}).$$

但此时总 stochastic first-order oracle complexity 是

$$T \times m = T^2,$$

所以要使 gap 小于 ε ，SFO complexity 仍约为

$$O(\varepsilon^{-4}).$$

这就是为什么只看 iteration rate 会显得很快，但把 batch cost 算进去后并没有免费午餐。[Sfyraki and Wang, 2025]

9 Kim-Oh: finite-step Newton-Schulz 如何进入主定理

这是 practical Muon 理论最关键的一篇。

设 momentum matrix 为 N_t , 其 exact polar factor 为

$$P_t = \text{msign}(N_t).$$

实际 Muon 用 q 次 Newton-Schulz iteration 得到

$$O_t = \text{NS}_q(N_t).$$

定义 approximation error

$$\varepsilon_q \sim \sup_t \|O_t - P_t\|_{\text{op}}.$$

9.1 Proof 中最关键的拆分

把实际 NS direction 与 exact polar direction 分开:

$$\begin{aligned} \langle \nabla f(W_{t-1}), O_t \rangle_F &= \langle N_t, O_t \rangle_F \\ &\quad + \langle \nabla f(W_{t-1}) - N_t, O_t \rangle_F. \end{aligned}$$

第一项再写成

$$\begin{aligned} \langle N_t, O_t \rangle_F &= \langle N_t, P_t \rangle_F + \langle N_t, O_t - P_t \rangle_F \\ &= \|N_t\|_* + \langle N_t, O_t - P_t \rangle_F. \end{aligned}$$

利用 Hölder inequality,

$$|\langle N_t, O_t - P_t \rangle_F| \leq \|N_t\|_* \|O_t - P_t\|_{\text{op}} \leq \varepsilon_q \|N_t\|_*.$$

所以

$$\boxed{\langle N_t, O_t \rangle_F \geq (1 - \varepsilon_q) \|N_t\|_*}.$$

这相当于把 exact-polar descent 中的 coefficient 1 换成

$$1 - \varepsilon_q.$$

因此最终收敛界只多出一个 multiplicative factor

$$\boxed{\chi_q = \frac{1}{1 - \varepsilon_q}}.$$

9.2 Theorem 1

其主定理具有形式

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E} \|\nabla f(W_{t-1})\|_* \leq \chi_q O \left(\sqrt{\frac{LD}{T}} + \sqrt{\frac{\sigma r}{BT}} + \left(\frac{r\sigma^2 LD}{BT} \right)^{1/4} \right),$$

其中

$$D = f(W_0) - f^*.$$

也就是说, finite-step NS 不改变关于 T 、 B 、 σ 的 rate, 只改变常数。

9.3 Theorem 2: double-exponential approximation

对于 degree- κ 的 Newton-Schulz polynomial, 论文证明

$$\varepsilon_q \leq 1 - \sqrt{1 - \delta_0^{(\kappa+1)^q}} \leq \delta_0^{(\kappa+1)^q}, \quad 0 < \delta_0 < 1.$$

于是

$$\chi_q \leq \frac{1}{\sqrt{1 - \delta_0^{(\kappa+1)^q}}}.$$

因为指数本身是

$$(\kappa + 1)^q,$$

所以误差随 q 以 doubly exponential speed 衰减:

$$\varepsilon_q \lesssim \exp(-c(\kappa + 1)^q).$$

这就是为什么实践中只做很少几次 Newton-Schulz iteration, 理论上就已经与 exact SVD-polar 非常接近。[Kim and Oh, 2026]

10 Chang-Liu-Yuan: MVR2 如何把 $T^{-1/4}$ 提升到 $T^{-1/3}$

这篇的关键不是修改 matrix sign, 而是修改 momentum estimator。

10.1 MVR1

MVR1 的一般形式是

$$M_t = \beta_t M_{t-1} + (1 - \beta_t) \nabla f(X_t; \xi_t) + \gamma_t \beta_t (\nabla f(X_t; \xi_t) - \nabla f(X_{t-1}; \xi_{t-1})).$$

这里差分使用不同随机样本, 所以差分项自身仍包含较大噪声。

10.2 MVR2: same-sample gradient difference

MVR2 改成

$$M_t = \beta_t M_{t-1} + (1 - \beta_t) \nabla f(X_t; \xi_t) + \gamma_t \beta_t (\nabla f(X_t; \xi_t) - \nabla f(X_{t-1}; \xi_t)).$$

关键是括号中的两个梯度使用**同一个** ξ_t 。

于是

$$\nabla f(X_t; \xi_t) - \nabla f(X_{t-1}; \xi_t)$$

主要反映位置移动造成的 gradient drift, 而不是两个独立噪声之差。

随后仍然是

$$O_t = \text{msign}(M_t), \quad X_{t+1} = X_t - \eta_t O_t.$$

10.3 MVR2 tracking recursion

令

$$A_t = \mathbb{E} \|M_t - \nabla f(X_t)\|_F^2.$$

MVR2 可以推出类似

$$A_{t+1} \leq (1 - \epsilon_{t+1}) A_t + C_\sigma \epsilon_{t+1}^2 + C_L \|X_{t+1} - X_t\|_F^2.$$

因为

$$\|X_{t+1} - X_t\|_F^2 = \eta_t^2 \|O_t\|_F^2 \leq n\eta_t^2,$$

所以

$$A_{t+1} \lesssim (1 - \epsilon_{t+1})A_t + \sigma^2 \epsilon_{t+1}^2 + L^2 n \eta_t^2.$$

相比普通 EMA, 这个 recursion 对 drift 的控制更精细。

10.4 与 descent inequality 的耦合

论文得到的关键结构可写为

$$\Delta_{t+1} \leq \Delta_t - \eta_t \mathbb{E} \|\nabla f(X_t)\|_F + L^{-1} \eta_t^{2/3} A_t + \left(\frac{L}{2} + Ln \right) \eta_t^{4/3},$$

其中

$$\Delta_t = \mathbb{E}[f(X_t) - f^*].$$

选择

$$\eta_t = t^{-2/3}, \quad \beta_t = 1 - \eta_t, \quad \gamma_t = 1,$$

使得:

$$\sum_{t=1}^T \eta_t \asymp T^{1/3},$$

而累计 tracking error 只产生 logarithmic factor。

因此 Theorem 4.2 给出

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E} \|\nabla f(X_t)\|_F \leq \frac{G_T}{T^{1/3}} = \tilde{O}(T^{-1/3}),$$

其中 G_T 只以 $O(\log T)$ 增长。

相比之下, MVR1 选择

$$\eta_t = t^{-3/4}, \quad \beta_t = 1 - t^{-1/2}$$

得到

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E} \|\nabla f(X_t)\|_F = \tilde{O}(T^{-1/4}).$$

所以真正突破 $T^{-1/4}$ bottleneck 的是:

$$\text{same-sample two-point variance reduction,}$$

而不是 matrix orthogonalization 本身。

10.5 PL condition

他们还采用

$$\|\nabla f(X)\|_F^2 \geq 2\mu(f(X) - f^*).$$

于是 gradient stationarity 可以转换为 objective gap。例如 MVR2 可得到 best-iterate 级别的

$$\min_{1 \leq t \leq T} \mathbb{E} \sqrt{f(X_t) - f^*} = \tilde{O}(T^{-1/3}).$$

若要证明 last-iterate objective convergence, 还需要额外的 uniform gradient bound 等条件。[Chang et al., 2025]

11 NAMO / NAMO-D: 怎样把 Adam-style adaptation 接到 Muon 上

11.1 Assumptions

论文使用 spectral/nuclear matching smoothness:

$$\|\nabla L(\Theta) - \nabla L(\Theta')\|_* \leq L\|\Theta - \Theta'\|_{\text{op}},$$

以及

$$\mathbb{E}\|G_t - \nabla L(\Theta_{t-1})\|_F^2 \leq \frac{\sigma^2}{b}.$$

11.2 NAMO update

First moment:

$$M_t = \mu_1 M_{t-1} + (1 - \mu_1)G_t.$$

Scalar second moment:

$$v_t = \mu_2 v_{t-1} + (1 - \mu_2)\|G_t\|_F^2.$$

正交方向:

$$O_t = \text{Orth}(M_t).$$

Adaptive scalar:

$$\alpha_t = \frac{\sqrt{1 - \mu_2^t} \|M_t\|_F}{1 - \mu_1^t \sqrt{v_t} + \varepsilon}.$$

更新:

$$\Theta_t = \Theta_{t-1} - \eta \alpha_t O_t.$$

11.3 Bias correction 写成 convex combination

定义

$$\widehat{M}_t = \frac{M_t}{1 - \mu_1^t}, \quad \widehat{v}_t = \frac{v_t}{1 - \mu_2^t}.$$

则

$$\widehat{M}_t = \sum_{\tau=1}^t w_{1,t,\tau} G_\tau,$$

$$\widehat{v}_t = \sum_{\tau=1}^t w_{2,t,\tau} \|G_\tau\|_F^2,$$

其中

$$w_{j,t,\tau} = \frac{1 - \mu_j}{1 - \mu_j^t} \mu_j^{t-\tau},$$

且

$$w_{j,t,\tau} \geq 0, \quad \sum_{\tau=1}^t w_{j,t,\tau} = 1.$$

这一步很重要, 因为它把 Adam 式的 bias-corrected moment 变成了真正的 weighted average, 之后可以使用 Jensen inequality 和 drift/noise decomposition。

11.4 Surrogate function

由于 descent 中会出现类似

$$\frac{\|\widehat{M}_t\|_F}{\sqrt{\widehat{v}_t} + \varepsilon_t} \|\nabla L(\Theta_{t-1})\|,$$

作者引入 surrogate

$$\phi_\varepsilon(x) = \frac{x^2}{x + \varepsilon}.$$

它满足

$$0 \leq \phi_\varepsilon(x) \leq x,$$

且当 $x \gg \varepsilon$ 时,

$$\phi_\varepsilon(x) \approx x.$$

证明先控制

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E} \phi_{\varepsilon_t} (\|\nabla L(\Theta_{t-1})\|_F),$$

再利用

$$x \leq \phi_\varepsilon(x) + \varepsilon$$

或相应变形, 恢复普通 gradient-norm bound。

11.5 Deterministic rate

选择

$$\eta = O(T^{-1/2}), \quad \varepsilon = O(T^{-1/2}),$$

并保持

$$\mu_1, \mu_2 = \Theta(1),$$

Theorem 3 给出

$$\frac{1}{T} \sum_{t=1}^T \|\nabla L(\Theta_{t-1})\|_F = O(T^{-1/2}).$$

11.6 Stochastic rate

取

$$\begin{aligned} \eta &= O(T^{-3/4}), \\ 1 - \mu_1 &= \Theta(T^{-1/2}), \quad 1 - \mu_2 = \Theta(T^{-1/2}), \\ \varepsilon &= O(T^{-1/2}), \end{aligned}$$

Theorem 4 得到

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E} \|\nabla L(\Theta_{t-1})\|_F \leq O\left(T^{-1/4} + \frac{\sqrt{\sigma}}{b^{1/4}T^{1/8}}\right).$$

这个界被称为 noise-adaptive, 因为当 σ 很小或 batch 很大时, 第二项自动减弱。

但也要注意: 如果 b 固定, 第二项只有

$$T^{-1/8},$$

可能在渐近上成为主项。要恢复纯粹的 $T^{-1/4}$, 需要让 batch 与 T 适当增长。

11.7 NAMO-D

NAMO-D 做 neuron-wise diagonal adaptation:

$$d_t = N_c(\widehat{M}_t) \odot (\sqrt{\widehat{v}_t} + \varepsilon_t).$$

令

$$\bar{d}_t = \frac{\|d_t\|_1}{n},$$

并做 clamping:

$$\tilde{d}_t = \min \left\{ \max \{d_t, c\bar{d}_t \mathbf{1}\}, \frac{\bar{d}_t}{c} \mathbf{1} \right\}.$$

定义

$$D_t = \text{diag}(\tilde{d}_t),$$

更新为

$$\Theta_t = \Theta_{t-1} - \eta O_t D_t.$$

Clamping 保证

$$d_{\min} \geq c^2 d_{\max},$$

即 diagonal scaling 的 condition number 被控制。

关键矩阵 lemma 是

$$\boxed{\langle M, OD \rangle_F \geq d_{\min} \|M\|_*},$$

其中

$$O = \text{Orth}(M), \quad D \succeq d_{\min} I.$$

这条不等式替代了普通 Muon 中的

$$\langle M, O \rangle_F = \|M\|_*.$$

因此只要 $d_{\min}$ 不退化, diagonal adaptation 不会破坏 descent alignment。[Zhang et al., 2026]

12 Nagashima–Iiduka: 统一 learning-rate / batch schedule 上界

这篇的核心是先给一个不指定 schedule 的 master bound，再代入 constant、polynomial、cosine schedule。

12.1 Algorithm

$$M_t = \beta M_{t-1} + (1 - \beta) \nabla f_{B_t}(W_t).$$

普通版本：

$$C_t = M_t.$$

Nesterov 版本：

$$C_t = \beta M_t + (1 - \beta) \nabla f_{B_t}(W_t).$$

Orthogonalization：

$$O_t \in \arg \min_{O^\top O = I} \|O - C_t\|_F.$$

更新：

$$W_{t+1} = W_t - \eta_t O_t.$$

12.2 Theorem 3.1 的 master bound

普通 Muon 的上界可以写为

$$\begin{aligned} \min_{0 \leq t < T} \mathbb{E} \|\nabla f(W_t)\|_F &\leq \frac{C_1}{\sum_{t=0}^{T-1} \eta_t} \\ &\quad + C_2 \frac{\sum_{t=0}^{T-1} \eta_t^2}{\sum_{t=0}^{T-1} \eta_t} \\ &\quad + C_3 \frac{\sum_{t=0}^{T-1} \eta_t \beta^t}{\sum_{t=0}^{T-1} \eta_t} \\ &\quad + C_4 \frac{\sum_{t=0}^{T-1} \eta_t \sum_{i=1}^t \beta^i \eta_{t-i}}{\sum_{t=0}^{T-1} \eta_t} \\ &\quad + C_5 \frac{\sum_{t=0}^{T-1} \eta_t \sum_{i=0}^t \beta^i / \sqrt{b_{t-i}}}{\sum_{t=0}^{T-1} \eta_t}. \end{aligned}$$

其中可取

$$\begin{aligned} C_1 &= f(W_0) - f^*, \\ C_2 &= \frac{nL}{2}, \\ C_3 &= 2\sqrt{n}\|M_0 - \nabla f(W_0)\|_F, \\ C_4 &= 2nL, \\ C_5 &= 2(1 - \beta)\sigma\sqrt{n}. \end{aligned}$$

这些项的意义分别是：

$$\begin{aligned} \frac{1}{\sum \eta_t} & \quad \text{optimization progress,} \\ \frac{\sum \eta_t^2}{\sum \eta_t} & \quad \text{smoothness penalty,} \\ \frac{\sum \eta_t \beta^t}{\sum \eta_t} & \quad \text{initial momentum error,} \\ \frac{\sum_t \eta_t \sum_i \beta^i \eta_{t-i}}{\sum \eta_t} & \quad \text{gradient drift,} \\ \frac{\sum_t \eta_t \sum_i \beta^i / \sqrt{b_{t-i}}}{\sum \eta_t} & \quad \text{stochastic noise.} \end{aligned}$$

12.3 Constant schedule

若

$$\eta_t = \eta, \quad b_t = b,$$

则

$$\begin{aligned} \sum_{t < T} \eta_t &= T\eta, \\ \frac{\sum \eta_t^2}{\sum \eta_t} &= \eta, \end{aligned}$$

而 momentum geometric sums 是 bounded constants, 所以

$$\boxed{\min_{t < T} \mathbb{E} \|\nabla f(W_t)\|_F = O\left(\frac{1}{\eta T} + \eta + \frac{1}{\sqrt{b}}\right)}.$$

进一步取

$$\eta = T^{-1/2}, \quad b = T,$$

得到

$$O(T^{-1/2}).$$

若更激进地取

$$\eta = T^{-1}, \quad b = T^2,$$

则形式上得到

$$O(T^{-1}).$$

但这里必须强调：这个 $O(T^{-1})$ 依赖每一步 batch size 达到 T^2 ，因此总 oracle cost 约为

$$T^3.$$

它不意味着 fixed-batch stochastic Muon 获得了 T^{-1} 的 oracle-efficient convergence。

12.4 Diminishing schedule

若

$$\eta_t = \frac{\eta}{\sqrt{t+1}},$$

则

$$\sum_{t=0}^{T-1} \eta_t \asymp \sqrt{T},$$

$$\sum_{t=0}^{T-1} \eta_t^2 \asymp \log T,$$

所以

$$\frac{\sum \eta_t^2}{\sum \eta_t} = O\left(\frac{\log T}{\sqrt{T}}\right).$$

最终得到

$$\boxed{\min_{t < T} \mathbb{E} \|\nabla f(W_t)\|_F = O\left(\frac{\log T}{\sqrt{T}} + \frac{1}{\sqrt{b}}\right)}.$$

这篇论文的“更快 rate”主要来自 schedule 和 growing batch，而不是 orthogonalization 给出新的 stochastic lower-bound breakthrough。[Nagashima and Iiduka, 2026]

13 把这些证明放在同一张逻辑图中

13.1 第一类：ordinary momentum tracking

Li-Hong、Shen、Sato 的核心 recursion 都近似为

$$e_t = M_t - \nabla f(X_t),$$

$$e_t = \beta e_{t-1} + (1 - \beta)\xi_t + \beta(\nabla f(X_{t-1}) - \nabla f(X_t)).$$

因而

$$\mathbb{E}\|e_t\| \lesssim \underbrace{\sigma\sqrt{1-\beta}}_{\text{variance}} + \underbrace{\frac{L\eta}{1-\beta}}_{\text{drift}}.$$

代入 master descent:

$$\frac{1}{T} \sum_t \mathbb{E}\|\nabla f(X_t)\| \lesssim \frac{\Delta}{T\eta} + L\eta + \sigma\sqrt{1-\beta} + \frac{L\eta}{1-\beta}.$$

需要同时让

$$1 - \beta \downarrow 0$$

以降低 stochastic variance, 又不能太小, 否则

$$\frac{\eta}{1-\beta}$$

爆炸。平衡这些项就自然产生

$$\boxed{T^{-1/4}}.$$

13.2 第二类：variance-reduced momentum

MVR2 利用 same-sample difference, 把 tracking error 改造成近似平方递推:

$$A_{t+1} \leq (1 - \eta_t)A_t + O(\eta_t^2).$$

于是大体上

$$A_t = O(\eta_t),$$

而不是普通 EMA 中较差的 drift-variance trade-off。

取

$$\eta_t = t^{-2/3}$$

后,

$$\sum_{t=1}^T \eta_t \asymp T^{1/3},$$

最终得到

$$\boxed{\tilde{O}(T^{-1/3}).}$$

13.3 第三类: approximate orthogonalization

Kim-Oh 的结构是

$$\text{exact descent coefficient} = 1$$

变成

$$\text{approximate descent coefficient} = 1 - \varepsilon_q.$$

所以 rate 被乘上

$$\chi_q = \frac{1}{1 - \varepsilon_q},$$

而

$$\varepsilon_q \leq \delta_0^{(\kappa+1)^q}.$$

因此有限步 Newton-Schulz 主要影响 constant, 不改变 rate exponent。

13.4 第四类: constraint / Frank-Wolfe geometry

这里不再控制简单的

$$\|\nabla f(X_t)\|,$$

而控制

$$\mathcal{G}(X) = \frac{1}{\lambda} \|\nabla F(X)\|_* + \langle X, \nabla F(X) \rangle.$$

这个量恰好是 spectral ball 上的 Frank-Wolfe gap, 同时也对应 KKT residual。

因此它回答的问题是:

$$\boxed{\text{Muon 是否收敛到 spectral-norm constrained problem 的 KKT point?}}$$

而不仅是

$$\boxed{\text{unconstrained Euclidean gradient 是否趋于零?}}$$

References

1. Jiaxiang Li, Mingyi Hong, *A Note on the Convergence of Muon*, arXiv:2502.02900, 2025.
<https://arxiv.org/pdf/2502.02900>
2. Wei Shen, Ruichuan Huang, Minhui Huang, Cong Shen, Jiawei Zhang, *On the Convergence Analysis of Muon*, arXiv:2505.23737, 2025.
<https://arxiv.org/pdf/2505.23737>
3. Naoki Sato, Hiroki Naganuma, Hideaki Iiduka, *Convergence Bound and Critical Batch Size of Muon Optimizer*, arXiv:2507.01598, 2025.
<https://arxiv.org/pdf/2507.01598>
4. Dmitry Kovalev, *Understanding Gradient Orthogonalization for Deep Learning via Non-Euclidean Trust-Region Optimization*, arXiv:2503.12645, 2025.
<https://arxiv.org/pdf/2503.12645>
5. Lizhang Chen, Jonathan Li, Qiang Liu, *Muon Optimizes Under Spectral Norm Constraints*, arXiv:2506.15054.
<https://arxiv.org/pdf/2506.15054>
6. Maria-Eleni Sfyraiki, Jun-Kun Wang, *Lions and Muons: Optimization via Stochastic Frank-Wolfe*, arXiv:2506.04192.
<https://arxiv.org/pdf/2506.04192>
7. Gyu Yeol Kim, Min-hwan Oh, *Convergence of Muon with Newton–Schulz*, arXiv:2601.19156 / ICLR 2026.
<https://arxiv.org/pdf/2601.19156>
8. Da Chang, Yongxiang Liu, Ganzhao Yuan, *On the Convergence of Muon and Beyond*, arXiv:2509.15816.
<https://arxiv.org/pdf/2509.15816>
9. Minxin Zhang, Yuxuan Liu, Hayden Schaeffer, *Adam Improves Muon: Adaptive Moment Estimation with Orthogonalized Momentum*, arXiv:2602.17080.
<https://arxiv.org/pdf/2602.17080>
10. Shuntaro Nagashima, Hideaki Iiduka, *Improved Convergence Rates of Muon Optimizer for Nonconvex Optimization*, arXiv:2601.19400.
<https://arxiv.org/pdf/2601.19400>

从 proof 学习顺序看，最清晰的一条路线是：

Shen Thm. 4.7 $\rightarrow$ Kim–Oh Thm. 1–2 $\rightarrow$ Chang Thm. 4.2 $\rightarrow$ NAMO stochastic theorem.

它依次对应：**基础 spectral descent**、**finite NS error**、**variance reduction**、**adaptive moment coupling**。